

1. Introduction

Les données utilisées dans cette étude proviennent de 1231 patients atteints de cancer du sein et comprennent à la fois des informations cliniques et des données génomiques. L'objectif est d'explorer et de comprendre ces données afin de construire un modèle de classification binaire capable de prédire le statut vital (*vital_status*) des patients. Cette étude consiste en une classification binaire en grande dimension. Les variables cliniques fournissent des informations sur le profil des patients (ex : age, genre, ethnicité...) et les caractéristiques de la tumeur (ex : taille de la tumeur, classification AJCC, stade pathologique...), tandis que les variables génomiques ($p \gg n$) reflètent l'expression de gènes clés associés au cancer du sein. L'analyse vise à identifier les tendances, les distributions, les valeurs manquantes, ainsi que les variables les plus discriminantes pour prédire si une patiente est vivante (Alive) ou décédée (Dead).

2. Exploration des données cliniques

2.1 Analyse de la Cible et Déséquilibre

Les données cliniques mêlent variables numériques et catégorielles (*race*, *morphology*, etc.). La variable cible est *vital_status*. L'exploration révèle un déséquilibre de classe significatif (voir Figure 1) : 84 % des patientes sont en vie contre seulement 16 % décédées. Ce déséquilibre imposera l'usage de métriques adaptées lors de la modélisation.

2.2 Valeurs manquantes et Linéarité

L'analyse des valeurs manquantes montre que moins de 7 % des données sont absentes, ce qui ne justifie pas une imputation lourde. Quelques patients présentent toutefois un taux de paramètres manquants très élevé (jusqu'à 75 %), nécessitant une imputation ciblée.

Nous avons également exploré les liens potentiels entre les variables cliniques et la survie. Les variables numériques, prises individuellement, ne permettent pas de distinguer clairement les patientes selon leur statut vital. L'examen des relations deux à deux (Figure 2) confirme cette observation : les scatterplots ne révèlent aucun motif ou séparation notable entre les classes. Les seules tendances légèrement linéaires concernent les variables liées à l'âge.

2.3 Analyse des densités

L'analyse des densités des variables numériques (Figure 3) révèle un fort chevauchement entre les distributions des patients vivants (Vert) et décédés (Rouge). Les densités ont été normalisées, ce qui permet de comparer les formes des distributions malgré la forte différence d'effectifs entre les deux groupes. Bien que l'on observe un léger décalage vers des valeurs d'âge plus élevées chez les patients décédés (*age_at_diagnosis*), aucune variable clinique ne présente, à elle seule, une séparation claire entre les classes.

2.4 Analyse des distributions et T-test

Nous avons généré les boxplots pour l'ensemble des variables numériques afin de comparer leurs distributions et détecter d'éventuelles valeurs atypiques. On peut par exemple mettre en évidence la distribution de l'âge au diagnostic (Figure 4). La médiane d'âge des patientes décédées est supérieure à celle des vivantes, ce qui suggère que l'âge est un facteur pronostique pertinent à inclure dans le modèle final. Le boxplot met également en évidence quelques valeurs atypiques, qui pourront être prises en compte lors du traitement des données avant l'analyse.

L'application du t-test (avec correction de Bonferroni) révèle plus clairement des différences de moyennes significatives entre les deux pronostiques vitaux. Le test confirme que l'âge est un facteur discriminant : les variables 'age_at_diagnosis' et 'age_at_index' indiquent que les patients décédés étaient statistiquement plus âgés (61 vs 58 ans, $P_{adj} \approx 0.03$). Le test isole également 'days_to_last_follow_up' comme la variable la plus significative ($P_{adj} < 0.001$), bien que ce résultat reflète un biais technique de suivi (suivi interrompu au décès) propre aux données de survie.

3. Conclusion Préliminaire

L'analyse exploratoire des données cliniques met en évidence l'absence de séparabilité nette entre les classes sur la base des seuls descripteurs standards. De plus, le fort chevauchement des densités et l'absence de corrélations linéaires fortes indiquent que ces variables, portent un signal prédictif insuffisant. Par conséquent, l'information discriminante nécessaire pour une classification performante réside vraisemblablement dans la complexité biologique. Cela justifie pleinement l'intégration des données génomiques dans la suite de l'étude.




Figure 1: Répartition du dataset.




Figure 2: Scatterplot matrices selon le statut vital.




Figure 3: Densités selon le statut vital.




Figure 4: Distribution de l'âge selon le statut vital.

3 Exploration des Données Génomiques (GeneX)

3.1 Description des Données et Enjeux Statistiques

Le jeu de données **GeneX** est une matrice de dimension 1231×5000 . Chaque colonne correspond à une variable explicative quantitative continue représentant le niveau d'expression d'un gène spécifique pour un patient donné. L'examen des données brutes (via **summary**) confirme l'absence de valeurs manquantes et la nature numérique des variables. Le défi majeur de ce projet réside dans le ratio dimensionnel $p \gg n$ (5000 variables $\gg$ 1231 observations). Cette structure implique mathématiquement que la matrice de covariance $X^T X$ est singulière (non inversible). Par conséquent, l'estimation des coefficients par les moindres carrés ordinaires (OLS) est impossible. Cette contrainte structurelle impose l'utilisation de méthodes de régularisation (type Lasso, Ridge ou Elastic-Net) ou de réduction de dimension.

3.2 Approche Univariée : Identification de marqueurs (T-Test)

Face à la dimensionnalité élevée ($p = 5000$), la multiplication des tests statistiques augmente le risque de Faux Positifs. Pour garantir la robustesse des résultats, nous avons appliqué la correction de Bonferroni, qui ajuste le seuil de significativité en le divisant par le nombre de tests ($\alpha_{adj} = \frac{0.05}{5000} = 10^{-5}$).

Conclusion T-test : L'analyse identifie ainsi les biomarqueurs les plus discriminants, répartis en deux profils opposés : une signature de **risque** surexprimée chez les patients décédés (**LINC01235**, **APOB**, **PSD2**, **AC104211.1**, **LYVE1**) et une signature **protectrice** favorisant la survie (**SNORD104**, **RHBDL1**, **RPS4Y1**, **CST1**, **SFTP8**). La validation visuelle (**Figure 1**) confirme la séparation des distributions pour ces candidats.




FIGURE 1 – Distributions des niveaux d'expression des 10 gènes les plus significatifs selon le T-test. Les boîtes rouges correspondent aux patients décédés (Dead) et les boîtes vertes aux patients vivants (Alive).

3.3 Approche Multivariée : Projection avec PCA + CCA

Pour capturer les structures de corrélation (synergies entre gènes) et contourner la singularité de la matrice, nous avons appliqué une stratégie séquentielle :

1. **PCA** ($k = 100$) : Projection sur les composantes principales, capturant **45% de la variance totale**. Ce seuil respecte la contrainte de robustesse statistique ($k \approx n/10$) tout en conservant le signal biologique majeur.
2. **CCA** : Recherche des combinaisons linéaires maximisant la corrélation avec la survie.

Conclusion PCA/CCA : La remontée des coefficients vers l'espace initial ($W = V \cdot A$) permet d'interpréter la contribution de chaque gène comme un poids. Cette analyse multivariée met en évidence une signature latente robuste (Figure 2). Contrairement à l'approche univariée, elle isole un cluster protecteur (C5orf17, IP6K3, AC021148.2, H2BU1) s'opposant aux facteurs de risque surexprimés chez les patients décédés (LINC00668, MPPED1, SLC6A3, PSD2, AC034243.1, OR7A5).




FIGURE 2 – Distributions des niveaux d'expression des 10 gènes les plus significatifs (PCA+CCA). Les boîtes rouges (Dead) s'opposent aux vertes (Alive) selon le signe du coefficient.

3.4 Conclusion et Perspective de Modélisation

L'exploration met en évidence la complémentarité des approches : le T-test sélectionne des effets marginaux forts, tandis que la PCA révèle des interactions latentes. Ces résultats justifient l'utilisation future de l'Elastic-Net. Cette méthode est idéale ici car elle combine la sélection de variables (Lasso) pour éliminer le bruit et la régularisation de groupe (Ridge) pour conserver les gènes corrélés identifiés par notre analyse multivariée.